

智能法律助手需求规格说明书（SRS）

项目	内容
项目名称	Intelligent Legal Assistant（基于 RAG 的智能法律问答与文档管理系统）
版本/日期	v1.0 / 2026-07-16
作者	Intelligent Legal Assistant Team
运行约束	CPU、可离线运行；LLM/Embedding 可替换为 Mock；禁止依赖公网
保密级别	内部考试材料

版本修订记录

版本	日期	说明
v1.0	2026-07-16	初版，覆盖文档处理、RAG 问答、权限与测试验收

1 引言、范围与术语

目标是将 PDF/DOC/DOCX/TXT 法律资料处理为可检索知识库，并通过带来源引用的 RAG 问答辅助法律检索。范围包括用户认证、会话、文档上传/处理、语义检索、问答、来源展示和管理接口；不提供自动法律裁判或未经审核的法律意见。

系统应在单机 CPU、离线条件下运行，外部模型不可用时使用 MockLLM/本地 Embedding。评测维度为可运行性、检索相关性、回答完整性、引用准确性、权限安全、鲁棒性；验收证据放在 deliver_doc/evidence/，代码证据见 backend/app/、frontend/src/。

术语：RAG（检索增强生成）、Chunk（文本块）、Embedding（向量表示）、Top-k（前 k 条检索结果）、RBAC（基于角色的访问控制）。引用格式统一为 [{company}::{year}:p{page}]，项目文档引用采用 [ILA:2026:path]。

2 总体描述

2.1 用户与场景

普通用户上传法规并提问；管理员维护用户、角色、权限和文档分类；评测人员执行批量问答与回归测试。典型流程：登录 → 上传文档 → 解析/清洗/切块 → 生成向量并写入 Milvus → 语义检索 → Prompt 组装 → LLM/MockLLM → 引用解析 → 返回答案和来源。

2.2 端到端流程

能力	SRS 落点		
文档解析	FR-01, document_processor/*		
清洗切块	FR-02/03, preprocessors.py、chunk_strategies.py		
向量检索	FR-04/05, langchain_processor/retrieval_service.py、vector_store/		
问答与引用	FR-06/07/09, services/chat/rag_service.py		
指标与验收	FR-08、NFR-04, deliver_doc/output/*测试*		
API/UI	FR-10, api/、frontend/src/		
ID	需求描述	输入/输出	验收口径

能力	SRS 落点		
FR-01	解析 PDF/DOC/DOCX/TXT，保留 <code>page/source/section</code>	文件 → Document[]	3 个样例文件成功率 100%；缺失文件返回 4xx
FR-02	去页眉页脚、断词修复、空白和标点归一、公司名规范化	Document → CleanDocument	清洗前后差异可审计，非法编码不崩溃
FR-03	固定切块 <code>chunk_size=500, overlap=50</code>	文本 → Chunk[]	每块含 <code>section/chunk_id</code> ；边界块不丢字
FR-04	本地向量索引，支持 Milvus；离线环境可切换内存 Mock	Chunk[] → index	首次创建、重启加载均成功；索

能力		SRS 落点	
		de x	引损坏 可重建
FR-05	语义检索 Top-k=5, 支持可选 BM25 混检及去重	qu er y → Evi de nc e[]	返回不 超过 5 条且引 用去 重; 命 中率达 到测试 阈值
FR-06	仅依据 CONTEXT 生成答案, 强制引用 <code>[{company}:{year}:p{page}]</code>	qu er y+ co nt ext → pr o m pt	无上下 文不得 编造; 引用非 空且格 式 100% 合规
FR-07	LLM/MockLLM 调用、超时和 JSON 解析降级	pr o m pt → pa ylo ad	解析失 败返回 可用 JSON 、保留 notes 和引用 兜底
FR-08	从 CSV 对齐 revenue、net_profit、solvency_ratio、total_assets、eps	an sw er +C	绝对/相 对误差 ≤5% 视 为一

能力		SRS 落点		
		SV → 校 验 结 果	致；否 则降 confid ence 并 写 notes	
FR-09	统一输出	answer,citations,used_metrics,confidence,notes	pa ylo ad → JS O N	字段齐 全、类 型正 确；引 用来源 真实存 在
FR-10	提供认证、会话、文档、搜索、问答 REST API	HT TP JS O N	关键接 口 2xx； 错误返 回统一 结构	
ID	要求	指标/验收		
NFR-01	CPU/离线 可运行	无公网时 E2E 成功率 100%（样例集）		
NFR-02	鲁棒性	空目录、缺列、坏索引、空检索、超长上下文均返回友好错误		
NFR-03	日志	INFO/ERROR/EXCEPTION 含加载量、chunk 数、检索数、耗时、降级原因		
NFR-04	性能	10 页样例端到端 ≤ 3 分钟；单问答 P95 ≤ 10 秒（CPU 基线）		

能力		SRS 落点	
NFR-05	可维护性	.env 可覆盖默认配置；目录、依赖和迁移脚本可复现	
NFR-06	安全	JWT Bearer、RBAC、上传类型/大小校验、用户数据隔离	
FR/NFR		测试用例	证据/缺陷
FR-01	Loader	TC-PDF-001, TC-DOC-002	evidence/loader.log
FR-02	Cleaner	TC-CLN-003	evidence/clean_diff.txt
FR-03	Chunker	TC-CHK-004	evidence/chunks.json
FR-04	Indexer	TC-IDX-005/006	evidence/index.log
FR-05	Retriever	TC-RET-007/008	evidence/retrieval.json
FR-06/07	Prompt/L	TC-PRM-009, TC-LLM-010	evidence/prompt.json

能力	SRS 落点		
	LM /Pa rse r		
FR-08	Val ida tor	TC-VAL-012	evid ence/m etric s.js on
FR-09/10	API /Sy nth esi zer	TC-OUT-011, TC-CLI-013	evid ence/a pi.js on
NFR-01~06	部 署/ 日 志/ 安 全	TC-NFR-014~018	evid ence/e 2e.lo g
状态	进入条件		允许操作 退出条件
uploaded	文件上传成功且通过扩展名校验		查看、删除、开始 处理任务启动

能力	SRS 落点		
		处理	
processing	Loader 已接收任务	查询进度、取消任务	全部 chunk 入库或失败
completed	索引和元数据写入成功	检索、问答、重新索引	删除或重新处理
failed	解析、存储或索引失败	查看错误、重试、删除	重试成功或删除

能力	SRS 落点		
实体/字段	数据类型	必填	约束/示例
User.id	U I D	是	主键
User.username	s t r i n g	是	3~64 字符，唯一
User.role	e n u m	是	admin/u ser/aud itor
Document.id	U I D	是	主键
Document.file_type	e n u m	是	pdf/doc /docx/t xt
Document.status	e n u m	是	uploade d/proce ssing/c omplete d/faile d

能力	SRS 落点		
Chunk.chunk_id	s t r i n g	是	docId- page- index
Chunk.page	i n t e g e r	是	≥1
Chunk.content	t e x t	是	UTF- 8, 最大 500 字 符 (可 含 overlap)
Message.role	e n u m	是	user/as sistant /system
Message.content	t e x t	是	非空, 最大 8,000 字符
Answer.citations	s t	是	正则 ^\\[[^:]+:\\d{

能力	SRS 落点		
	ring		4}:p\\d+\\]\$
Answer.confidence	number	是	0~1, 保留两位小数

图 1 端到端 RAG 业务流程图



可视化架构/流程图