

智能法律助手需求规格说明书（SRS）

项目	内容
项目名称	Intelligent Legal Assistant（基于 RAG 的智能法律问答与文档管理系统）
版本/日期	v1.0 / 2026-07-16
作者	Intelligent Legal Assistant Team
运行约束	CPU、可离线运行；LLM/Embedding 可替换为 Mock；禁止依赖公网
保密级别	内部考试材料

版本修订记录

版本	日期	说明
v1.0	2026-07-16	初版，覆盖文档处理、RAG 问答、权限与测试验收

1 引言、范围与术语

目标是将 PDF/DOC/DOCX/TXT 法律资料处理为可检索知识库，并通过带来源引用的 RAG 问答辅助法律检索。范围包括用户认证、会话、文档上传/处理、语义检索、问答、来源展示和管理接口；不提供自动法律裁判或未经审核的法律意见。

系统应在单机 CPU、离线条件下运行，外部模型不可用时使用 MockLLM/本地 Embedding。评测维度为可运行性、检索相关性、回答完整性、引用准确性、权限安全、鲁棒性；验收证据放在 `deliver_doc/evidence/`，代码证据见 `backend/app/`、`frontend/src/`。

术语：RAG（检索增强生成）、Chunk（文本块）、Embedding（向量表示）、Top-k（前 k 条检索结果）、RBAC（基于角色的访问控制）。引用格式统一为 [{company}]{year}:p{page}]，项目文档引用采用 [ILA:2026:path]。

2 总体描述

2.1 用户与场景

普通用户上传法规并提问；管理员维护用户、角色、权限和文档分类；评测人员执行批量问答与回归测试。典型流程：登录 → 上传文档 → 解析/清洗/切块 → 生成向量并写入 Milvus → 语义检索 → Prompt 组装 → LLM/MockLLM → 引用解析 → 返回答案和来源。

2.2 端到端流程

```
flowchart LR
    A[PDF/DOC/TXT] --> B[Loader]
    B --> C[Cleaner]
    C --> D[Chunker]
    D --> E[Embedding/Indexer]
    E --> F[Retriever Top-k]
    F --> G[Prompt + Context]
    G --> H[LLM/MockLLM]
    H --> I[Parser/Synthesizer]
    I --> J[引用与权限校验]
    J --> K[JSON/API/UI]
```

能力	SRS 落点
文档解析	FR-01, document_processor/*
清洗切块	FR-02/03, preprocessors.py、chunk_strategies.py
向量检索	FR-04/05, langchain_processor/retrieval_service.py、vector_store/
问答与引用	FR-06/07/09, services/chat/rag_service.py
指标与验收	FR-08、NFR-04, deliver_doc/output/*测试*

能力	SRS 落点
API/UI	FR-10, api/, frontend/src/

3 功能需求 (FR)

ID	需求描述	输入/输出	验收口径
FR-01	解析 PDF/DOC/DOCX/TXT, 保留 page/source/section	文件 → Document[]	3 个样例文件成功率 100%; 缺失文件返回 4xx
FR-02	去页眉页脚、断词修复、空白和标点归一、公司名规范化	Document → CleanDocument	清洗前后差异可审计, 非法编码不崩溃
FR-03	固定切块 chunk_size=500, overlap=50	文本 → Chunk[]	每块含 section/chunk_id; 边界块不丢字
FR-04	本地向量索引, 支持 Milvus; 离线环境可切换内存 Mock	Chunk[] → index	首次创建、重启加载均成功; 索引损坏可重建
FR-05	语义检索 Top-k=5, 支持可选 BM25 混检及去重	query → Evidence[]	返回不超过 5 条且引用去重; 命中率达到测试阈值
FR-06	仅依据 CONTEXT 生成答案, 强制引用 [{company}:{year}:p{page}]	query+context → prompt	无上下文不得编造; 引用非空且格式 100% 合规

ID	需求描述	输入/输出	验收口径
FR-07	LLM/MockLLM 调用、超时和 JSON 解析降级	prompt → payload	解析失败返回可用 JSON、保留 notes 和引用兜底
FR-08	从 CSV 对齐 revenue、net_profit、solvency_ratio、total_assets、eps	answer+CSV → 校验结果	绝对/相对误差 ≤5% 视为一致；否则降 confidence 并写 notes
FR-09	统一输出 answer,citations,used_metrics,confidence,notes	payload → JSON	字段齐全、类型正确；引用来源真实存在
FR-10	提供认证、会话、文档、搜索、问答 REST API	HTTP JSON	关键接口 2xx；错误返回统一结构

4 非功能需求 (NFR)

ID	要求	指标/验收
NFR-01	CPU/离线可运行	无公网时 E2E 成功率 100% (样例集)
NFR-02	鲁棒性	空目录、缺列、坏索引、空检索、超长上下文均返回友好错误
NFR-03	日志	INFO/ERROR/EXCEPTION 含加载量、chunk 数、检索数、耗时、降级原因

ID	要求	指标/验收
NFR-04	性能	10 页样例端到端 ≤ 3 分钟；单问答 P95 ≤ 10 秒 (CPU 基线)
NFR-05	可维护性	.env 可覆盖默认配置；目录、依赖和迁移脚本可复现
NFR-06	安全	JWT Bearer、RBAC、上传类型/大小校验、用户数据隔离

5 数据、接口与错误

数据目录：knowledge_document/ 原文， data/processed/ 清洗结果， data/vector_store/ 索引， data/eval/dev_set.jsonl 评测集， logs/ 运行日志。CSV 字段：
company(str),year(int),revenue(float,亿元),net_profit(float,亿元),solvency_ratio(float,%),total_assets(float,亿元),eps(float,元/股)。

核心 API：POST /api/auth/login、POST /api/chat/send、POST /api/documents/upload、POST /api/documents/search、GET /health。错误 JSON：
{ "error": true, "code": 400, "message": "...", "detail": "..."}；状态码
400/401/403/404/422/500 分别表示参数、认证、权限、资源、校验和服务错误。

6 验收、评测与追踪矩阵

通过标准：E2E 100%；引用格式合规率 100%；引用准确率 ≥90%；指标一致率 ≥ 90%；dev_set Acc ≥85%、平均 confidence ≥0.75；异常用例通过率 ≥95%。

FR/NFR	设计模块	测试用例	证据/缺陷
FR-01	Loader	TC-PDF-001, TC-DOC-002	evidence/loader.log

FR/NFR	设计模块	测试用例	证据/缺陷
FR-02	Cleaner	TC-CLN-003	evidence/clean_diff.txt
FR-03	Chunker	TC-CHK-004	evidence/chunks.json
FR-04	Indexer	TC-IDX-005/006	evidence/index.log
FR-05	Retriever	TC-RET-007/008	evidence/retrieval.json
FR-06/07	Prompt/LLM/Parser	TC-PRM-009, TC-LLM-010	evidence/prompt.json
FR-08	Validator	TC-VAL-012	evidence/metrics.json
FR-09/10	API/Synthesizer	TC-OUT-011, TC-CLI-013	evidence/api.json
NFR-01~06	部署/日志/安全	TC-NFR-014~018	evidence/e2e.log

7 风险与附录

风险：扫描 PDF 文本层缺失（P1，转 OCR/人工上传）；Milvus 不可用（P0，切内存索引）；模型输出非 JSON（P0，Mock/规则解析降级）；长上下文截断（P1，按块优先级裁剪）。每个 P0/P1 缺陷需至少一次回归并记录在测试报告。

附录证据路径约定：命令输出 `evidence/cli/*.json`，日志 `evidence/logs/*.log`，截图 `evidence/screenshots/*.png`，评测汇总 `evidence/eval_summary.csv`。

8 详细业务流程与状态定义

8.1 文档生命周期

状态	进入条件	允许操作	退出条件
uploaded	文件上传成功且通过扩展名校验	查看、删除、开始处理	处理任务启动
processing	Loader 已接收任务	查询进度、取消任务	全部 chunk 入库或失败
completed	索引和元数据写入成功	检索、问答、重新索引	删除或重新处理
failed	解析、存储或索引失败	查看错误、重试、删除	重试成功或删除

8.2 问答业务规则

1. 用户必须通过 JWT 认证，且只能检索本人或被授权的文档。
2. 检索结果按向量相似度降序排列；开启 BM25 时使用 $0.7 * \text{semantic} + 0.3 * \text{bm25}$ ，同一 document_id/chunk_id 去重。
3. Prompt 中每个证据块必须包含来源元数据，模型不得使用 CONTEXT 之外的信息；无证据时返回“未找到可靠来源”。
4. Parser 先尝试严格 JSON，再尝试 Markdown 代码块 JSON，最后生成 fallback payload；fallback 必须保留至少一条真实引用或明确标记无引用。
5. 指标校验以公司+年份为主键，数值采用绝对误差和相对误差双重判定，任一指标超过 5% 即记录 mismatch。

9 详细数据字典

实体/字段	类型	必填	约束/示例
User.id	UUID	是	主键
User.username	string	是	3~64 字符，唯一
User.role	enum	是	admin/user/auditor

实体/字段	类型	必填	约束/示例
Document.id	UUID	是	主键
Document.file_type	enum	是	pdf/doc/docx/txt
Document.status	enum	是	uploaded/processing/completed/failed
Chunk.chunk_id	string	是	docId-page-index
Chunk.page	integer	是	≥1
Chunk.content	text	是	UTF-8, 最大 500 字符 (可含 overlap)
Message.role	enum	是	user/assistant/system
Message.content	text	是	非空, 最大 8,000 字符
Answer.citations	string[]	是	正则 <code>^\\[[^:]+:\\d{4}:p\\d+\\]\$</code>
Answer.confidence	number	是	0~1, 保留两位小数

10 接口字段级规范

10.1 POST /api/chat/send

请求: `{"content": "...", "conversation_id": "uuid|null", "use_rag": true, "top_k": 5}`。
 响应: `message_id`、`content`、`intent`、`question_analysis`、`retrieved_docs[]`、`tokens_used`、`sources[]`；失败时返回统一错误对象。幂等键使用 `X-Request-ID`，重复请求不重复写入消息。

10.2 POST /api/documents/upload

使用 `multipart/form-data`，字段 `file`、`title`、`category_id`。限制单文件 50 MB、文件名 UTF-8、扩展名白名单；返回 `id/title/filename/file_size/status/created_at`。病毒扫描或解析失败时状态为 `failed`，不产生可检索 `chunk`。

10.3 POST /api/documents/search

请求 `{"query":"劳动合同解除","top_k":5,"use_bm25":false,"category_id":"uuid|null"}`；响应每条包含 `document_id,document_title,chunk_content,similarity,metadata{page,section,source}`。`top_k` 允许 1~20，超出返回 422。

11 可观测性与审计要求

每次请求生成 `trace_id`；日志字段包括

`timestamp,trace_id,user_id,operation,duration_ms,status,error_code`。管理员操作（用户、角色、文档删除、权限变更）写入审计表，保存 180 天。敏感字段（密码、token、API key）禁止写日志；异常堆栈仅在开发模式输出。