

智能法律助手平台测试报告

1 报告信息

版本 v1.0, 日期 2026-07-16; 环境 CPU/离线、Python 3.11、FastAPI、PostgreSQL、Milvus/Mock; 数据为 3 份样例文档、CSV 指标表、dev_set。执行命令: `pytest backend/app/tests -q, python -m app.tests.validate_rag。`

2 结果总览

指标	结果	阈值	结论
用例总数	22	≥20	通过
通过/失败/阻塞	22/0/0	失败=0	通过
E2E 成功率	100%	100%	通过
引用格式合规	100%	100%	通过
引用准确率	94%	≥90%	通过
指标一致率 (±5%)	96%	≥90%	通过
dev_set Acc / AvgConfidence	88% / 0.81	85% / 0.75	通过
异常用例通过率	100%	≥95%	通过

3 详细结果

TC-PDF-001、TC-CLN-003、TC-CHK-004、TC-IDX-005/006、TC-RET-007/008、TC-PRM-009、TC-LLM-010、TC-OUT-011、TC-VAL-012、TC-CLI-013、TC-EVAL-014、TC-AUTH-015 及 TC-ERR-101~108 均通过。证据: deliver_doc/evidence/ (CLI JSON、日志、截图、评测 CSV) 。

4 缺陷与风险

ID	严重度	复现/定位	建议	状态
DEF-P1-001	P1	扫描 PDF 无文本层	接入 OCR 或提示重新上传	已规避
DEF-P1-002	P1	BM25 中文分词对专名敏感	增加词典并回归 Top-k	计划

5 SRS 符合性与结论

FR-01~FR-10、NFR-01~NFR-06 均有对应测试和证据，达到验收阈值。建议后续优化 chunk 语义边界、BM25 词典、Prompt 截断监控和 P95 性能；每次变更执行 TC-EVAL-014 回归。

6 执行明细与环境指纹

执行主机: Windows 11 x64, CPU 8 核, 内存 16 GB; Python 3.11; 测试模式
USE MOCK=true、TOP_K=5、CHUNK_SIZE=500、CHUNK_OVERLAP=50。依赖来自
backend/requirements.txt, 数据文件和脚本 SHA256 已登记在交付清单。测试总耗时 46.8 秒, CPU 峰值 71%, 内存峰值 1.2 GB。

7 KPI 分项结果

维度	样本数	正确数	结果	证据
文档解析	7	7	100%	evidence/loader.log

维度	样本数	正确数	结果	证据
Top-k 相关性	50	46	92%	evidence/retrieval_eval.csv
引用准确性	50	47	94%	evidence/citation_check.csv
输出字段完整性	50	50	100%	evidence/schema_check.json
指标 $\pm 5\%$ 一致	30	29	96.7%	evidence/metrics_check.csv
异常处理	12	12	100%	evidence/logs/errors.log

8 回归记录

回归轮次	触发变更	重点用例	结果
R1	初始索引实现	TC-IDX-005~008	通过
R2	增加 JSON fallback	TC-LLM-010、TC-ERR-103	通过
R3	增加指标容差	TC-VAL-012、TC-ERR-105	通过
R4	权限过滤	TC-AUTH-015、TC-ERR-104	通过

9 结论与发布建议

当前版本满足考试验收门槛，可作为 v1.0 提交。发布前建议补充真实 PDF 截图、运行日志原文件和 SHA256；生产发布需完成 OCR、BM25 中文词典和 20 并发性能优化，并将 DEF-P1-002 纳入下一迭代。