

智能法律助手平台测试方案（含用例）

1 目标、范围与环境

目标：验证 SRS FR-01~FR-10、NFR-01~NFR-06，覆盖单元、组件、集成、E2E 和回归。环境：Windows/Linux、Python 3.9+、CPU、离线；后端 FastAPI，数据库 PostgreSQL，向量 Milvus 或 Mock，样例 PDF 3 份、key_metrics.csv、dev_set.jsonl。初始化：复制 .env.example，设置 USE MOCK=true、TOP_K=5，安装 backend/requirements.txt，运行 pytest backend/app/tests。

2 策略与通过准则

单元覆盖 Loader/Cleaner/Chunker/Validator；组件覆盖索引、检索、Prompt；集成覆盖 RAG 链；E2E 覆盖登录→上传→问答→引用。正向、反向、边界和回归均纳入。通过标准：E2E=100%，字段完整率=100%，引用准确率≥90%，指标一致率≥90%（±5%），dev_set Acc≥85%、AvgConfidence≥0.75，异常通过率≥95%。

3 用例

ID	关联	场景/步骤	预期
TC-PDF-001	FR-01	加载 3 个 PDF，检查 page/source	Document 字段完整
TC-DOC-002	FR-01	上传 DOCX/TXT	状态 completed，生成 chunks
TC-CLN-003	FR-02	输入页眉、断词、异常空格	清洗规则生效
TC-CHK-004	FR-03	chunk_size=500、overlap=50	块含 section/chunk_id
TC-IDX-005	FR-04	删除索引后 build	文件生成且可查询

ID	关联	场景/步骤	预期
TC-IDX-006	FR-04	重启后 load_local	日志显示复用
TC-RET-007	FR-05	query, Top-k=5	返回≤5 条证据
TC-RET-008	FR-05	开关 BM25, 对比去重	无重复, 召回不下降
TC-PRM-009	FR-06	构造含 5 条 context 的 prompt	仅使用 CONTEXT, 引用格式正确
TC-LLM-010	FR-07	Mock 返回 JSON/坏 JSON	正常解析或 fallback
TC-OUT-011	FR-09	执行问答	字段齐全、citations 非空
TC-VAL-012	FR-08	CSV 偏差 3%/8%	前者通过, 后者降 confidence 并 notes
TC-CLI-013	FR-10	调用 API/CLI	2xx JSON, 错误码规范
TC-EVAL-014	NFR-04	批量执行 dev_set	输出 Total/Correct/Acc/AvgConf
TC-AUTH-015	NFR-06	无 token/越权访问	401/403, 数据隔离
TC-ERR-101	NFR-02	删除 CSV 必填列	422, 列名清晰
TC-ERR-102	NFR-02	无关问题空检索	不崩溃, 引用为空并提示

ID	关联	场景/步骤	预期
TC-ERR-103	NFR-02	LLM 半截 JSON	fallback JSON, notes 保留
TC-ERR-104	NFR-02	删除引用	不得返回无引用成功
TC-ERR-105	FR-08	偏差>5%	mismatch notes、confidence 下降
TC-ERR-106	FR-04	破坏索引文件	自动重建或明确报错
TC-ERR-107	FR-05	不存在公司/年份	返回未找到来源
TC-ERR-108	NFR-04	超长上下文	裁剪后仍为合法 JSON

4 数据与证据

每条用例保存 `evidence/<case_id>.json`、`evidence/logs/<case_id>.log`；截图位于 `evidence/screenshots/`。格式校验脚本检查 `answer,citations,used_metrics,confidence` 和引用正则；评测脚本批量读取 `dev_set.jsonl` 输出 `evidence/eval_summary.csv`。

6 测试数据设计

数据集	数量	构成	用途
PDF 基线	3	可复制文本、表格、分页脚注	解析/引用
DOC/DOCX/TXT	各 2	中文条款、英文条款、空段落	格式兼容

数据集	数量	构成	用途
CSV 指标	30 行	5 公司×6 年，含缺失和异常值	指标校验
dev_set	50 条	事实、比较、无关、拒答问题	批量评测
异常集	12 条	坏文件、坏索引、缺列、超长输入	鲁棒性

数据生成规则：所有金额统一亿元、比率统一百分比、EPS 统一元/股；年份为 4 位整数；敏感数据使用脱敏公司名。每次执行记录文件大小、行数、SHA256，避免测试数据漂移。

7 覆盖率矩阵

能力	单元	组件	集成	E2E	用例
Loader	Y	Y	Y	Y	001/002
Cleaner/Chunker	Y	Y	Y	Y	003/004
Indexer/Retriever	Y	Y	Y	Y	005~008
Prompt/LLM/Parser	Y	Y	Y	Y	009/010/011
Validator	Y	Y	Y	Y	012
API/Auth	Y	Y	Y	Y	013/015
NFR 异常	-	Y	Y	Y	101~108

8 自动化执行与退出码

```
python -m pytest backend/app/tests -q --junitxml=evidence/junit.xml
python -m app.tests.validate_rag --dataset data/eval/dev_set.jsonl --output
evidence/eval_summary.csv
python scripts/check_output_schema.py evidence/cli/*.json
```

脚本退出码：0=全部通过；1=功能失败；2=环境或数据缺失；3=指标低于阈值。CI 必须上传 JUnit、日志、JSON、CSV 四类制品。

9 性能与安全测试

性能测试使用 1/5/20 并发、100 次问答，记录平均/P50/P95/P99 延迟、CPU 峰值和内存峰值；P95 超过 10 秒判失败。安全测试包含未认证访问、越权文档、路径穿越、超大文件、恶意扩展名、Prompt 注入；任何越权成功均为 P0。

5 风险与回归

PDF 扫描件、Milvus 不可用、模型输出漂移、上下文截断为 P0/P1 风险；修复后至少执行关联用例和全量 TC-EVAL-014。每次版本记录缺陷 ID、复现命令、日志片段、回归轮次。